

TRỢ LÝ ẨM THỰC AI · AI FOOD ASSISTANT

VSF Merchant Management AI

Nền tảng quản lý merchant & trợ lý gợi ý nhà hàng thông minh

Báo cáo đề án nhóm — tập trung vào **phần thực hiện của tác giả** (trục Customer: trợ lý AI gợi ý nhà hàng, UC-04 & UC-05), trong nền tảng VSF Merchant Management AI.

Sinh viên thực hiện: Giáp Minh Hiếu

Mentor hướng dẫn: Đỗ Đức Kiên

Ngày nộp: 01 / 08 / 2026 · **Phiên bản:** 1.0

Mục lục

1. Tổng quan dự án
2. Use cases & phạm vi
3. Kiến trúc hệ thống
4. Tech stack
5. Thiết kế AI Agent (Customer)
6. Dữ liệu & phương pháp chấm điểm
7. Giao diện người dùng
8. Đánh giá & kết quả
9. Thách thức & giải pháp
10. Hướng phát triển
- P. Phụ lục

1 Tổng quan dự án

VSF Merchant Management AI là nền tảng trung tâm phục vụ hệ sinh thái *VSF Merchant*. Hệ thống kết hợp **quản trị dữ liệu merchant** (nhà hàng/quán ăn) với một **trợ lý AI hội thoại** phục vụ hai nhóm người dùng: **Khách hàng** (tìm & gợi ý quán ăn) và **Chủ merchant** (chẩn đoán điểm yếu, đề xuất cải thiện, phân tích đối thủ).

Phạm vi đóng góp (đề án nhóm 2 người). Phần em (Giáp Minh Hiếu): trực **Customer** — UC-04 (tìm kiếm) + UC-05 (sở thích/bối cảnh), AI Agent khách hàng (crew tuần tự, multi-turn, grounding, clarify gates), frontend Customer, eval ground-truth; và **tầng data chung** (schema, merchant profiles, scoring 8 dimension, dataset) — đây là trọng tâm báo cáo. **Đồng đội Minh:** trực **Merchant** — agent UC-01/02/03 (chẩn đoán/đề xuất/đối thủ cho chủ merchant).

1.1 · Vấn đề giải quyết

- **Khách** khó chọn quán phù hợp giữa hàng ngàn lựa chọn theo khẩu vị, ngân sách, vị trí & thời điểm (thời tiết).
- **Chủ merchant** không biết vì sao quán ít đơn, cải thiện điều gì trước, và đang kém đối thủ ở điểm nào.
- **Vận hành:** cần tìm kiếm không gian (lân cận) nhanh, không phụ thuộc extension nặng (PostGIS).

Triết lý cốt lõi

Mọi đánh giá là **đa chiều** (multi-dimension) kèm **evidence truy vết được** — thay vì một "điểm tổng" dễ gây hiểu lầm. Agent **không bịa** khi thiếu dữ liệu, nói **"chưa có thông tin"** thay vì suy đoán.

1.2 · Mục tiêu

- Tra cứu nhà hàng theo ràng buộc tự nhiên (món, giá, khoảng cách, đánh giá) với lọcgeo chính xác.
- Trợ lý đa lượt (multi-turn), ghi nhớ sở thích & bối cảnh (thời tiết, vị trí).
- Trung thực tối thượng: claim phải có evidence; thiếu evidence → từ chối, không hallucinate.
- An toàn: dị ứng/thực đơn nhạy cảm phải xác nhận; chống injection/SQLi; xử lý ngoài phạm vi (OOD).

1.625

MERCHANTS

5

USE CASES

8

SCORING DIMS

39/39

GT EVAL

27/27

UNIT TESTS

2 Use cases & phạm vi

Dự án quy định 5 use case (UC-01..05). Trục **Customer (UC-04/05)** đã được xây dựng trọn vẹn end-to-end và là trọng tâm báo cáo này. Trục **Merchant (UC-01/02/03)** đã có design + scoring + data sẵn, agent flow ở mức target/thiết kế.

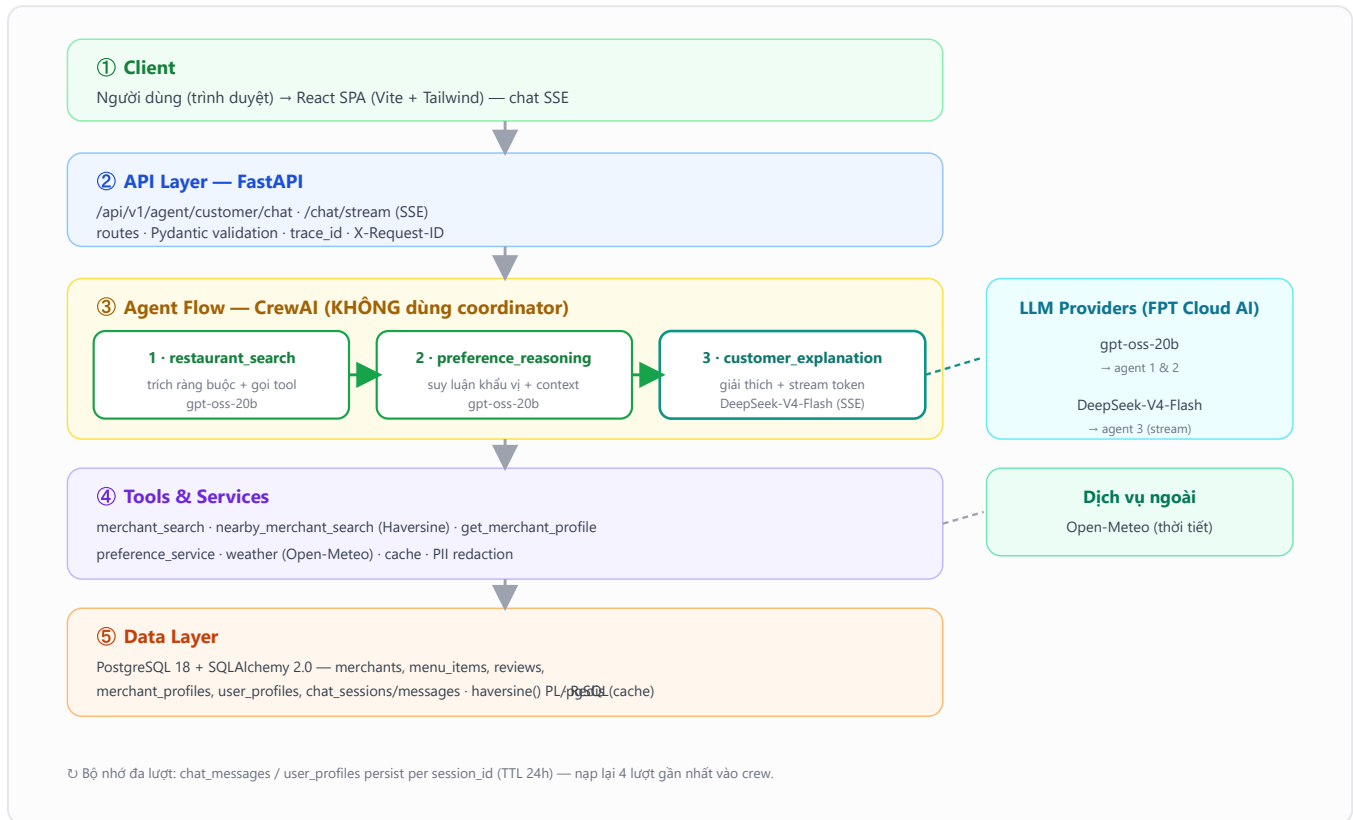
UC	Nhóm	Mô tả	Trạng thái
UC-01	Merchant	Diagnosis — chẩn đoán nguyên nhân ít đơn theo dimension yếu nhất + evidence (vd: <code>waiting_time 0.15</code> , prep 34').	Design + data
UC-02	Merchant	Recommendation — đề xuất hành động ưu tiên, gán dimension + evidence + estimated impact.	Design + data
UC-03	Merchant	Competitor — so sánh công khai từng dimension với cụm đối thủ lân cận; cấm claim KPI nội bộ.	Design + data
UC-04	Customer	Restaurant search — tra cứu theo món/giá/khoảng cách (Haversine), lọc hard-constraint end-to-end.	Hoàn thành
UC-05	Customer	Preference + Context — gợi ý theo sở thích đã xác nhận + thời tiết; tạo preference suggestion (chưa persist).	Hoàn thành

Phân công: UC-01/02/03 (Merchant) — đồng đội **Minh**; UC-04/05 (Customer) — **em (Hiếu)**, trọng tâm báo cáo.

Ví dụ UC-04 (thực tế chạy). Query "Tìm quán phở gần Cầu Giấy" → Agent trả lời hội thoại: "Ờ, Cầu Giấy á? Mình thấy có Cuốn Xưa - Phở Cuốn Hà Thành ... rating 4.6 khá ổn ..." kèm 3 merchant card (#1 Cuốn Xưa 4.6, #2 Anh Béo - Bún Miến Ngan 4.7, #3 Bánh Mì Chủ Tiệu 4.8) với match score & khoảng cách.

3 Kiến trúc hệ thống

Hệ thống chia lớp rõ ràng: **Client** → **API** → **Agent Flow** → **Tools/Services** → **Dữ liệu**, với **LLM providers** và dịch vụ ngoài ở biên.



Hình 1 — Kiến trúc tổng quan 5 lớp. Trục Customer đi end-to-end; trục Merchant dùng cùng data/scoring layer.

3.1 · Luồng xử lý một truy vấn (SSE)

- Frontend** gửi query + `session_id` + `location` (+ tùy chọn `weather_override`) tới `/chat/stream`.
- Pre-search guard** (tắt định, không LLM): rỗng/OOD/dị ứng/báo giá mơ hồ/thiếu vị trí → chặn hoặc yêu cầu làm rõ ngay.
- Crew tuần tự**: search → preference → explanation; agent explanation **stream token** về client qua SSE (TTFT thấp).
- Persist user + agent turn (kèm `structured_payload_json`: result_merchant_ids) → phục vụ *anaphora* lượt sau.
- Mỗi bước ghi `agent_events` (task/tool, duration) theo `trace_id` — quan sát được toàn vẹn.

4 Tech stack

Backend

- Python · **FastAPI** + Pydantic
- **CrewAI** (sequential crew, standalone)
- **SQLAlchemy 2.0** + Alembic migrations
- PostgreSQL 18 (JSONB, PL/pgSQL `haversine()`)
- Redis (cache adapter — CachePort)
- SSE streaming

Frontend

- React 19 + TypeScript
- Vite · Tailwind CSS v4
- react-router · react-markdown
- lucide-react (icons)

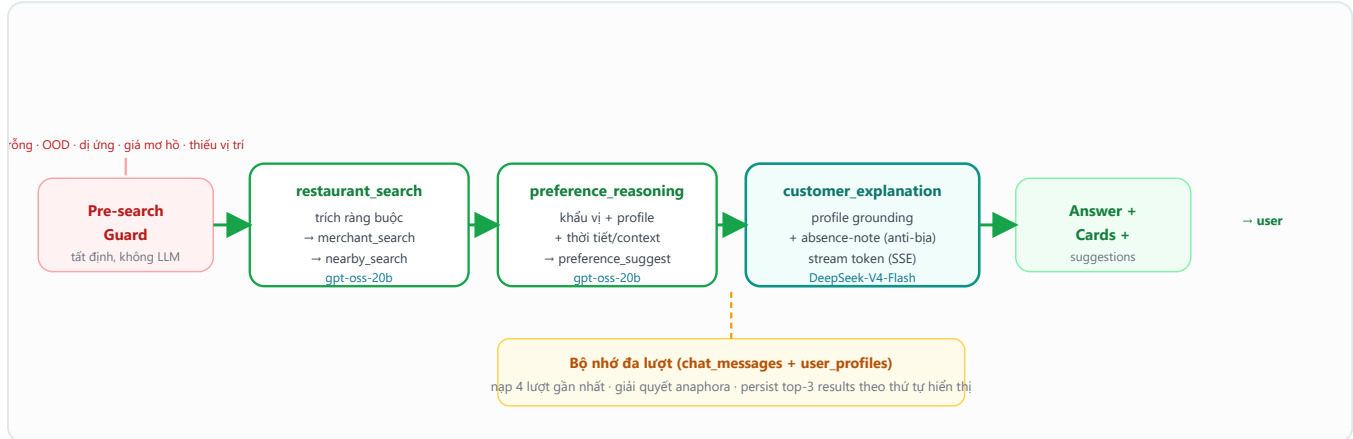
AI / LLM

- **gpt-oss-20b** (search/preference)
- **DeepSeek-V4-Flash** (explanation, stream)
- Open-Meteo (weather context)

Infra & chất lượng. Docker Compose (Postgres + Redis riêng từng dev) · trace_id + `agent_events` observability · **27/27 unit test xanh** · eval harness ground-truth (`eval_ground_truth.py`) · SQLi escape + Pydantic bounds validation.

5 Thiết kế AI Agent (Customer)

Đây là phần kỹ thuật cốt lõi và tốn công nhất. Trục Customer dùng **crew tuần tự không coordinator** — một quyết định thiết kế cố ý: thay vì một LLM "router" (coordinator) phân phối — vốn dễ hallucinate và chậm — hệ thống dùng **các guard tất định + pipeline cố định**, vừa tin cậy vừa dễ kiểm chứng.



Hình 2 — Pipeline Customer Agent: guard tất định → 3 agent tuần tự (không coordinator) → output, với vòng lặp bộ nhớ đa lượt.

5.1 · Đa lượt & bộ nhớ (multi-turn memory)

Mỗi phiên chat (`session_id`) persist user + agent turn vào `chat_messages` ; 4 lượt gần nhất được nạp lại vào crew (TTL 24h). Agent turn lưu `structured_payload_json` với `result_merchant_ids` theo đúng **thứ tự hiển thị** — để lượt sau giải quyết tham chiếu chính xác.

5.2 · Giải quyết tham chiếu (anaphora resolution)

Câu như "quán đầu tiên", "cái đó", "hai quán kia" được giải quyết tất định bằng ordinal/referent detector đọc payload lượt trước. Kết hợp với **profile grounding** để trả lời đúng đối tượng — không phụ thuộc tên quán khớp chuỗi.

5.3 · Profile grounding & trung thực tối thượng

Anti-confabulation. Khi Agent được hỏi *giá* hoặc *độ cay* mà profile **không có** trường đó (vd `price_level` chỉ định tính "rẻ/cao cấp", **không có giá số; không có trường cay**), hệ thống ghép một **absence-note cứng** ngay cạnh dữ liệu: "TUYỆT ĐỐI KHÔNG bịa con số / không bịa độ cay". Kết quả: thay vì bịa "vài chục nghìn" hoặc "bún đậu vốn không cay", Agent nói "chưa có giá cụ thể — mức giá dạng rẻ" / "không có thông tin độ cay trong dữ liệu".

5.4 · Cổng bắt buộc làm rõ (mandatory-clarify gates)

B1 · Báo giá mơ hồ. Một con số trần (1-3 chữ số) trong ngữ cảnh ngân sách, không đơn vị → hỏi rõ đơn vị "50 nghìn / 500 nghìn / 50 triệu?" trước khi tìm. Triple-protected để không bắn nhầm (vd "5.0 sao", "1 tuần", "50.000đ").

B2 · Thiếu vị trí thưa. Chỉ có từ món ăn, không prior, không vị trí, không động từ ý định → hỏi khu vực trước khi tìm. Cả hai gate được verify chỉ kích hoạt đúng 1 case mỗi loại trên toàn 39 case.

5.5 · An toàn (safety envelope)

- **Dị ứng / thực đơn nhạy cảm:** quét prior turn, nếu có dị ứng + món → **bắt buộc xác nhận** trước khi tìm (loại bỏ rủi ro sức khỏe).
- **OOD / injection:** ngoài phạm vi hoặc chèn prompt → từ chối tinh táo; **SQLi:** escape ký tự LIKE (\ % _) + Pydantic bounds (lat/lng/radius).
- **So sánh/origin thiếu data:** từ chối trung thực, không bịa KPI nội bộ đối thủ.

6 Dữ liệu & phương pháp chấm điểm

Tầng data (schema, merchant profiles, scoring) do em xây — phần chung nuôi cả hai trục Customer & Merchant.

6.1 · Schema (9 bảng chính)

`merchants` · `menu_items` (JSONB cuisine/diet tags) · `reviews` · `delivery_feedbacks` · `food_images` · `operational_metrics` · `merchant_profiles` · `user_profiles` · `chat_sessions` / `chat_messages`. Tìm kiếm không gian dùng hàm PL/pgSQL `haversine()` phía server — nhanh, indexable, không cần PostGIS.

6.2 · Các trường dữ liệu (field)

Các bảng chia 4 nhóm: thực thể merchant, profile chấm điểm, bằng chứng/vận hành, và runtime/customer. Score dùng một thang chuẩn `0..1`; `overall_score_internal` là cột sinh tự động (bình quân 8 score), **chỉ nội bộ**.

merchants — thực thể nhà hàng

Trường	Kiểu	Ý nghĩa
<code>merchant_id</code>	text PK	Mã merchant, khóa chính (theo ID nguồn)
<code>name</code> · <code>cuisine</code> · <code>city</code> · <code>city_slug</code>	text	Tên, loại ẩm thực, thành phố — dùng để lọc
<code>lat</code> · <code>lng</code>	double	Tọa độ (cặp cùng null/cùng có) → Haversine tìm lân cận
<code>opens_at</code> · <code>closes_at</code>	time	Giờ mở/đóng cửa
<code>taste_tags</code> · <code>diet_tags</code> · <code>ingredient_tags</code>	text[]	Tag đa giá trị: hương vị / chế độ ăn / nguyên liệu
<code>is_active</code> · <code>is_demo_target</code>	bool	Đang hoạt động / thuộc cohort demo (5 hero)

merchant_profiles — điểm đa chiều (output scoring)

Trường	Kiểu	Ý nghĩa
<code>tier</code>	text	<code>hero</code> (evidence giàu) hoặc <code>background</code>
<code>price_level</code>	text	Định tính: <code>rẻ</code> / <code>trung bình</code> / <code>cao cấp</code> — không phải giá số
8 cột <code>*_score</code>	numeric 0..1	food / image / delivery / packaging / service / waiting_time / menu_diversity / price_competitiveness
<code>overall_score_internal</code>	generated	Bình quân 8 score — không bao giờ hiển thị ra ngoài (chỉ QA nội bộ)

Bảng chứng & vận hành (merchant)

Bảng	Trường chính
merchant_dimension_evidence	Số liệu truy vết: value_numeric/text/boolean + reference_ids — đi kèm mỗi claim/điểm
merchant_complaints	Khiếu nại theo category + severity (trừ điểm dimension tương ứng)
operational_metrics	avg_prep_time_min , on_time_rate , driver_rating , packaging_ok_rate , peak_hours ...
reviews / delivery_feedbacks	Đánh giá (rating 0..10, text, sentiment) / phản hồi giao hàng (on_time, issue, driver_rating)
menu_items / food_images	Món (price, likes, ảnh, category) / chất lượng ảnh món

Runtime / Customer (phiên chat, trace agent)

Bảng	Trường chính
user_profiles	liked/disliked_cuisines (JSONB), spice_tolerance , dietary , budget_level , distance_preference_km , current_lat/lng
chat_messages	sender (user/agent), text , trace_id , structured_payload_json (lưu result_merchant_ids theo thứ tự → giải quyết anaphora lượt sau)
chat_sessions	session_id , user_id , context_snapshot_json , last_trace_id
preference_events	Audit append-only: field , operation , status (candidate→confirmed), evidence_refs — không ghi đè user_profiles
agent_runs / agent_events	trace_id , crew_name , task/tool, duration_ms , status — quan sát toàn vẹn mỗi lần chạy

6.3 · 8 dimension chấm điểm merchant

Mỗi merchant có merchant_profiles chấm theo 8 dimension — mỗi dimension là hàm thuần trả (score 0–1, evidence[], basis), tất định & tái lập. Bảng tóm tắt:

Dimension	Tín hiệu chính	Complaint trừ điểm
food_quality	rating 0.55 · sentiment 0.30 · popularity 0.15	chất_lượng_món, món_nguội (−0.03)
image_quality	vision (hero) / photo coverage (bg)	—
delivery_quality	on_time 0.5 · driver 0.3 · time 0.2	giao_hàng_trễ (−0.03)
packaging	packaging_ok_rate	đóng_gói_kém (−0.05)
service	rating_norm	thái_độ_phục_vụ (−0.06)
waiting_time	avg_prep_minutes	giao_hàng_trễ (−0.03)
menu_diversity	dish_count 0.6 · dish_type 0.4	—
price_level	ratio vs peer_median cùng cuisine	— (đặt phản ánh qua ratio)

 **Rule cứng.** `overall_score` (bình quân 8 dimension) **không bao giờ hiển thị** ra ngoài — một điểm yếu mạnh bị pha loãng nếu gộp (vd `waiting=0.15` nhưng `overall=0.66` vẫn "khá"). Thay vào đó luôn trả **per-dimension + evidence**. Enforce ở API response & Agent prompt.


6.4 · Dataset & kịch bản

Tổng **1.625 merchant**, trong đó **18 hero** (reviews/complaints/vision thật+synthetic → evidence giàu), **5 hero** được gán **1 điểm yếu tất định** có chủ đích để demo chẩn đoán:


ID	Tên	Điểm yếu chủ đích	Dimension thấp
233150	Sushi Lounge (Vũng Tàu)	slow_prep	waiting_time 0.15
10344	Popeyes - Tùng Thiện Vương	weak_delivery	delivery_quality 0.35
100810	3 Râu - Gà Rán/Pizza	weak_packaging	packaging 0.30
13909	(Hải Phòng)	weak_food	food_quality 0.57
68814	Dì Bảy - Bún Mắm	weak_service	service 0.58

7 Giao diện người dùng


Frontend React (Vite + Tailwind) với theme xanh mint thân thiện. Sidebar điều hướng (Trang chủ / Trò chuyện / Khám phá / Sở thích), khu vực chat trung tâm và merchant card bên phải. Mỗi card: thứ hạng #1/#2/#3, ảnh món, tên, cuisine, rating sao, và **match score**. Dưới đây là 5 luồng truy vấn đại diện: trang chủ, tra cứu cơ bản, bối cảnh thời tiết, lọc ngân sách, và đa lượt (giải quyết tham chiếu + trung thực giá).




Hình 3 — **Trang chủ** (chụp từ app đang chạy, phiên bản hiện tại): hero "Ăn gì hôm nay? Để mình gợi ý cho.", thanh tìm kiếm, 6 prompt gợi ý nhanh (phở, trà sữa chill, trời mưa, dưới 50k, Nhật hẹn hò, chay) và 3 feature card (Hiểu khẩu vị / Gần & hợp / Đúng thời điểm).




Hình 4 — **Tra cứu UC-04** (phiên bản hiện tại, đã fix stream): "Tìm phở gần Cầu Giấy" → câu trả lời hội thoại tự nhiên + 3 card kết quả (Cuốn Xưa 4.6 / Anh Béo 4.7 / Bánh Mì Chú Tiểu 4.8) kèm match score. Không còn lỗi stream.



Hình 5 — **Nhạy bối cảnh thời tiết (UC-05)** (phiên bản hiện tại): "Trời mưa lạnh, thêm phở nóng gần Cầu Giấy" → Agent hiểu bối cảnh mưa lạnh, gợi ý món nước nóng hổi (bún miến nước dùng đậm đà) + 3 card khu vực Cầu Giấy/Tây Hồ (Anh Béo 4.7, Bami Sot 4.9, Aussie Burger 4.7).




Hình 6 — **Lọc ràng buộc ngân sách (UC-04)** (phiên bản hiện tại): "Ăn trưa dưới 50k gần Cầu Giấy" → hard-filter giá end-to-end, trả 3 card hợp ngân sách (Anh Béo 4.7, Bento Delichi 4.6, Bánh Mì Chú Tiểu 4.8).



Hình 7 — **Đa lượt & giải quyết tham chiếu + trung thực** (phiên bản hiện tại): lượt 1 tìm bún bò → lượt 2 hỏi "quán đầu tiên giá bao nhiêu?" → Agent giải quyết đúng "quán đầu tiên" = Bún Bò Huế 2Bro (lượt 1) & thành thật trả giá: "chưa có giá cụ thể, phân khúc cao cấp" (không bịa con số).

8 Đánh giá & kết quả

Hệ thống được đo trên **ground-truth 39 case** (12 case coordinator-only bị bỏ qua công bằng). Mỗi case: seed profile + replay prior turn + POST test turn tới `/chat/stream`, chấm bởi judge LLM (eval-fidelity-aware).



Hình 8 — Qualify arc: 59% → 69% → 87% → 100%. Mốc 87% là phép đo **đầu tiên không nhiễm** (session sạch); 100% sau khi đóng 5 fail cuối (anaphora + clarify).

8.1 · Độ tin cậy

31% → 2.6%

SEARCH TIMEOUT (5S→15S)

~10-30% → ~1%

STREAM INTERRUPT

Stream reliability. Endpoint DeepSeek (FPT) hay drop giữa chừng / stall. Fix: **thử stream (timeout 30s) → retry → fallback non-stream (45s)**. Tỷ lệ lỗi ~10-30% giảm xuống ~1%. Phục hồi non-stream emit warning để quan sát được.

27/27

UNIT TESTS XANH

5/5

FAIL CUỐI ĐÓNG (JUDGE)

0

LỖI / GIÁN ĐOẠN (39 CASE)

~1.9s

MEDIAN EXPLAIN STREAM

9 Thách thức & giải pháp

9.1 · Confabulation (LLM bịa khi thiếu data)

Rule "trung thực tối thượng" đã có trong prompt nhưng DeepSeek vẫn bỏ qua — bịa giá ("vài chục nghìn") và độ cay ("bún đậu vốn không cay"). **Giải pháp:** `_profile_grounding` nhận diện attribute được hỏi; nếu profile thiếu → ghép **absence-note cứng** ngay cạnh data, cấm bịa. Kết quả: trả lời trung thực.

9.2 · Stream interrupt (mất câu trả lời giữa chừng)

Endpoint DeepSeek (FPT) đôi khi drop/stall giữa chừng → cảnh báo `explanation_stream_interrupted`, khiến câu trả lời bị mất (chỉ còn lời xin lỗi). Fix: thử stream (timeout 30s) → retry → **fallback non-stream** (45s) — metric & chi tiết ở §8.1 (tỉ lệ ~10-30% → ~1%). Sau fix, cùng dạng query trả lời sạch, hội thoại tự nhiên (xem Hình 4).

9.3 · Eval fidelity — phép đo bị "nhiễm"

Các vòng đo đầu tái dùng `session_id` cố định trong khi DB persist `chat_messages` → đọc **prior turn cũ** → confabulation. Số "69%" vốn đo trên session nhiễm; **87% (arch-seam) là con số đầu tiên đáng tin**. Fix: per-run stamp → session/user id duy nhất mỗi lần chạy.

9.4 · Anaphora với prior rỗng. Harness lấy toạ độ chỉ từ test message, nhưng case đa lượt để vị trí ở *prior turn* → prior replay tìm không vị trí → rỗng → không có referent. Fix: toạ độ lấy từ `prior + test`. Đây là fix leverage cao nhất, giúp 3 case anaphora hoạt động đúng.

10 Hướng phát triển

1. **Search relevance prior-turn**: một số case (lỗi → bunn riều surfaced đầu) — tinh chỉnh retrieval (phần Customer).
2. **Result card đã lượt**: case TC-41 trả lời đúng nhưng thiếu card (n_results=0) — gap nhỏ ở FE Customer.
3. **Đa lượt sâu hơn**: lan truyền ràng buộc giữa các lượt, mạnh hoá anaphora/ordinal.
4. **Production deployment (trực Customer)**: CI pipeline, performance test, cache + observability.

Trực **Merchant** (agent UC-01/02/03) là track riêng của đồng đội **Minh** — ngoài phạm vi báo cáo này.

Thuật ngữ

Thuật ngữ	Ý nghĩa
Crew / CrewAI	Khung điều phối nhiều agent; ở đây dùng sequential crew (tuần tự).
Coordinator	Agent router — đã cố ý loại bỏ thay bằng guard tắt định.
SSE	Server-Sent Events — stream token về client (TTFT thấp).
Anaphora	Tham chiếu như "quán đầu tiên", "cái đó" — cần giải quyết từ ngữ cảnh lượt trước.
Grounding	Gắn câu trả lời vào dữ liệu thật (profile) — cốt lõi chống hallucinate.
Dimension	Trục chấm điểm merchant (8 trục: food/service/packaging/...).
Evidence	Số liệu truy vết đi kèm mỗi claim/score.
Haversine	Công thức tính khoảng cách trái đất — dùng cho tìm kiếm lân cận.

Tài liệu tham chiếu (trong repo)

- docs/2026-07-21-merchant-ai-agent-complete-design.md — design AI agent đầy đủ.
- docs/scoring-methodology.md — công thức 8 dimension.
- docs/database-schema.md · docs/data-pipeline-and-dictionary.md — schema & pipeline.
- docs/development-roadmap.md · docs/project-changelog.md — lộ trình & lịch sử thay đổi.
- docs/demo-script.md · docs/sample-qa.md · docs/evaluation-plan.md — demo & eval.
- plans/reports/eval-260731-anaphora-clarify-final.md — báo cáo tối ưu customer agent.

Báo cáo này mô tả trạng thái tính đến 01/08/2026. **Trục Customer (UC-04/05) — do em thực hiện** — hoàn thành end-to-end & đo 39/39 ground-truth. Trục Merchant (agent UC-01/02/03) do đồng đội **Minh** thực hiện; agent flow còn ở mức thiết kế.