

TRỢ LÝ ẨM THỰC AI · AI FOOD ASSISTANT

VSF Merchant Management AI

Bộ nhớ & cá nhân hoá — Sprint 2 (01/08 → 17/08/2026)

Tiếp nối Sprint 1 (trực Customer end-to-end, 39/39 GT eval). Sprint 2 biến lời hứa "**trợ lý ghi nhớ người dùng**" thành hiện thực: kho sở thích hợp nhất, bộ nhớ 3+1 lớp, ràng buộc chủ động, hệ metrics đánh giá.

Sinh viên thực hiện: Giáp Minh Hiếu

Mentor hướng dẫn: Đỗ Đức Kiên

Ngày nộp: 17 / 08 / 2026 · **Phiên bản:** 2.0

Mục lục

1. Tổng quan Sprint 2

Bối cảnh — mục tiêu — kết quả chính (con số)

2. Use case mục tiêu

UC-04 · UC-05 (trọng tâm) — Sprint 2 sâu hoá UC-05 bằng memory + enforcement

3. Pipeline — 3 mức chi tiết

L1 · input–output / L2 · tổng quát / L3 · chi tiết theo component

4. Kết quả đánh giá

Tests · GT eval · memory eval 28 case · metrics

5. Demo

Ảnh demo UI chạy thật — memory, suggestion, lịch sử hội thoại

1 Tổng quan Sprint 2

Sprint 1 bàn giao trực Customer **hoạt động end-to-end** nhưng agent chưa thật sự **nhớ**: Preference Center ghi localStorage (mất khi đổi máy), `context_memory` luôn rỗng, sở thích đã lưu không ảnh hưởng kết quả tìm kiếm. Sprint 2 đóng các khoảng trống đó.

Đã làm (4 khối chính):

- **Kho sở thích hợp nhất** — 1 store chuẩn `user_profiles` ; sửa tay (PATCH) và gợi ý qua chat (confirm) cùng một đường validate; FE cắt localStorage sang API.
- **Bộ nhớ 3+1 lớp** — structured profile / `context_memory` (TTL, retraction) / `prior_context` (4→16 lượt) + episodic likes; hardening 4 FAIL thật.
- **Ràng buộc chủ động** — dị ứng/diet lọc kết quả *mọi lượt* (kể cả "xin chào"), 3 tầng defense-in-depth.
- **Đánh giá + UX** — metrics tất định (P/R/F1), bộ test memory 28 case, lịch sử hội thoại kiểu ChatGPT.

33

COMMITTS (01/08→13/08)

127 → 243

UNIT TESTS XANH

39/39

GT EVAL PARITY

4/4

MEMORY FAIL ĐÃ ĐÓNG

Tóm tắt Sprint 2. Trước đây trợ lý mỗi lần chat là "quên hết": người dùng nói ăn chay, dị ứng gì đó thì trợ lý ghi vào sổ, nhưng khi gợi ý quán thì vẫn quảng đại những quán vi phạm — nhớ mà không dùng. Sở thích chỉ nằm trong trình duyệt, đổi máy là mất. Sprint 2 sửa tận gốc: mọi sở thích giờ lưu ở máy chủ, người dùng sửa tay hay chấp nhận gợi ý cũng về một chỗ; những điều hệ thống "nhớ" được chia theo độ bền — khẩu vị thì nhớ mãi, chuyện kiêng khem có thời hạn tự hết, nói "hết dị ứng rồi" thì xoá luôn cái cũ thay vì ghi thêm chữ mới đè lên. Quan trọng nhất: mọi gợi ý đều bị kiểm tra qua ràng buộc an toàn trước khi tới người dùng — ai dị ứng gì thì không bao giờ thấy quán món đó, kể cả khi chỉ vào hỏi han xã giao. Cuối cùng là trải nghiệm quen thuộc kiểu ChatGPT: lịch sử trò chuyện lưu lại, đổi tên xoá bỏ tìm lại được, mở phiên cũ thấy đủ ảnh như ban đầu.


2 Use case mục tiêu

UC	Nhóm	Mô tả	Sprint 1	Sprint 2
UC-04	Customer	Restaurant search — tra cứu món/giá/khoảng cách (Haversine), lọc hard-constraint end-to-end	Hoàn thành	Giữ + tăng cường (match-score graded, price-word normalizer)
UC-05	Customer	Preference + Context — gợi ý theo sở thích đã xác nhận + bối cảnh (thời tiết/vị trí)	Hoàn thành (suggest, chưa persist)	Trọng tâm: persist + ranking + memory + enforcement
UC-M	Customer	Memory & an toàn (mở rộng UC-05) — ghi nhớ xuyên phiên, dị ứng/diet lọc chủ động, rút lại, TTL	—	Mới: 3+1 lớp bộ nhớ, 4 FAIL đóng
UC-01/02/03	Merchant	Diagnosis / Recommendation / Competitor	Design + data	Track đồng đội Minh — ngoài phạm vi

Ví dụ UC-M (chạy thật). Người dùng: "Tôi hay ăn chay, dị ứng đậu phộng" → agent đề xuất 2 delta (chay trường 85%, dị ứng đậu phộng 90%) kèm evidence → bấm **Lưu** → ghi vào profile. Lướt sau mọi gợi ý đều né đậu phộng + ưu tiên chay. Nói "hết dị ứng rồi" → note cũ bị xóa, không còn chặn.


3 Pipeline — 3 mức chi tiết

L1 · Input — Output (hộp đen)




Hình 1 — L1: hệ thống như hộp đen. Vào: câu hỏi + vị trí + bộ nhớ. Ra: câu trả lời + cards + gợi ý khẩu vị, mọi kết quả đã lọc theo ràng buộc an toàn.

L2 · Tổng quát (5 lớp)



Hình 2 — L2: 5 lớp tổng quát. Chữ đậm = phần Sprint 2 thêm/bổ sung trên nền Sprint 1 (API profile, ranking, constraints, memory, lịch sử).

L3 · Chi tiết theo component (pipeline 1 truy vấn)



Hình 3 — L3: pipeline chi tiết một truy vấn theo component — guards → nạp bộ nhớ 3 lớp → build constraints → crew 3 agent + ranking → enforce 3 tầng → output/persist; nhánh suggestion → confirm (propose-only).

4 Kết quả đánh giá

243/243

UNIT TESTS XANH

39/39

GT EVAL PARITY MỖI
PHASE

82%

ROUTING ACCURACY
(METRICS MỚI)


0 FAIL

MEMORY EVAL 28 CASE
(TẮT ĐỊNH)


Hạng mục	Kết quả
GT metrics suite (mới)	Routing acc 82% · macro F1 0.80 — tắt định, không judge; pred_action theo tools-presence
Memory eval 28 case	8 nhóm × span 15–20 session, dùng code production thật: 16 PASS · 2 PARTIAL (granularity) · 0 FAIL · 10 LLM-dep . 4 FAIL thật (peanut safety, stale allergy, TTL, FIFO) đã fix + verify live
Quality judge độc lập	Multi-run 3×2 judge: mean ~71%, phân loại stable-pass 22 / borderline 11 / stable-fail 6
Coordinator experiment	Đo rời revert — net-neutral (ask-F1 +0.03, trong noise); giữ kiến trúc coordinator-free
Kiểm thử hồi quy	Mỗi phase Plan A đều GT-eval PARITY 39/39 trước khi giữ; unit 127 → 243 xanh

5 Demo


5.1 · Memory chi tiết (từng cơ chế)




Hình 4 — **Ràng buộc tạm thời (TTL)**: "tuần này ăn kiêng ít dầu mỡ" → hệ thống ghi có thời hạn 7 ngày, tự hết; agent vừa đáp ứng nhu cầu hiện tại vừa nhớ ràng buộc.



Hình 5 — **Rút lại (retraction)**: "hết dị ứng đậu phộng rồi" → note cũ bị xóa (không ghi đề mâu thuẫn); agent mừng cùng user và gợi ý lại món có đậu phộng — trước đó món này bị chặn.




Hình 6 — **Sau khi rút — lượt kế tiếp**: user chủ động hỏi món ăn vặt có đậu phộng → agent gợi ý thoải mái (gỏi cuốn, salad đậu phộng rang), KHÔNG còn confirm-gate — bằng chứng ràng buộc cũ đã gỡ sạch.




Hình 7 — **Recap bộ nhớ**: "Bạn nhớ những gì về tôi?" → agent liệt kê đúng trạng thái CUỐI: hết dị ứng đậu phộng, vẫn kiêng dầu mỡ tuần này, không còn giới hạn ngân sách — mọi thay đổi qua các lượt đều cập nhật nhất quán.

5.2 · Toàn cảnh luồng



Hình 8 — **Suggestion trong chat + lịch sử sidebar**: khai báo "ăn chay, dị ứng đậu phộng" → 2 delta có evidence + mức tin cậy; bấm **Lưu** ghi vào profile (propose-only: agent chỉ đề xuất). Sidebar: phiên cũ "3 ngày trước" (timestamp đúng giờ VN).



Hình 9 — **Preference Center sau khi xác nhận:** "Đã đồng bộ với máy chủ"; **Ghi nhớ của trợ lý** hiển thị context_memory (chay trường, kiêng dầu mỡ tuần này, thứ Hai chay tuyệt đối); nút **Xóa ghi nhớ** có confirm.

Báo cáo mô tả trạng thái đến 17/08/2026, tiếp nối Báo cáo Sprint 1 (01/08/2026). Chi tiết kỹ thuật: [docs/system-architecture.md](#) · plan + eval reports trong [plans/](#). Trục Merchant (UC-01/02/03) do đồng đội **Minh** thực hiện.